Non-local neural networks

- Reading the paper in terms of Non-local neural networks -

1. Introduction

Convolution은 엄밀하게 말하자면 local operator에 속한다. 연산시에 kernel의 크기만큼만 특징을 추출할 수 있기 때문입니다.

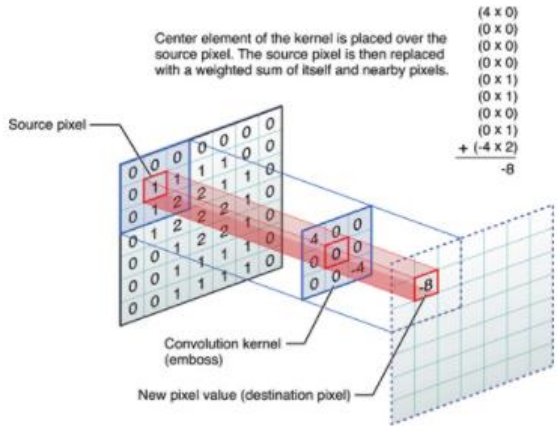

[그림1] Convolution

따라서 CNN의 경우 넓은 receptive field를 확보하기 위해(이미지의 더 넓은 부분을 보기 위해) convolution 연산을 여러 차례 겹쳐 쌓거나, pooling을 통해 이미지 자체를 요약해서 특징을 추출하기도 합니다. 하지만 이러한 방식은 receptive field를 일정 수준 확보할 수 있지만, 연산량 대비 효율의 측면에서 좋은 방식은 아닙니다. 이를 극복하고자 본 논문에서는 기존의 convolution의 local한 특성을 보완하기 위해, 한번의 연산이 영상 전체 영역을 대상으로 하는 non-local한 연산을 제안합니다. Non-local block이라고 정의한 이 레이어는 기존의 CNN에 손쉽게 적용 가능하고 이미지나, 비디오 분류 문제에서 큰 성능 향상을 보였습니다. Non-local block에 대한 설명에 앞서, 본 논문 아이디어의 토대가 된 non-local means filter라는 노이즈 필터에 대하여 먼저 간단하게 알아보겠습니다.

2. Background

Computer vision에서 이미지의 노이즈 제거 문제는 이미지 전처리 단계에서 굉장히 중요한 부분을 차지하고 있으며, 다양한 방법들이 제안되었습니다. 그 중에서도 non-local mean filter(NLM filter)는 노이즈 제거에서 큰 효과를 보였습니다. NLM filter는 노이즈를 제거하기 위해 한 장의 이미지 내에서 유사한 영역을 찾아 평균을 취해주는 방식을 이용해 denoising을 진행합니다.

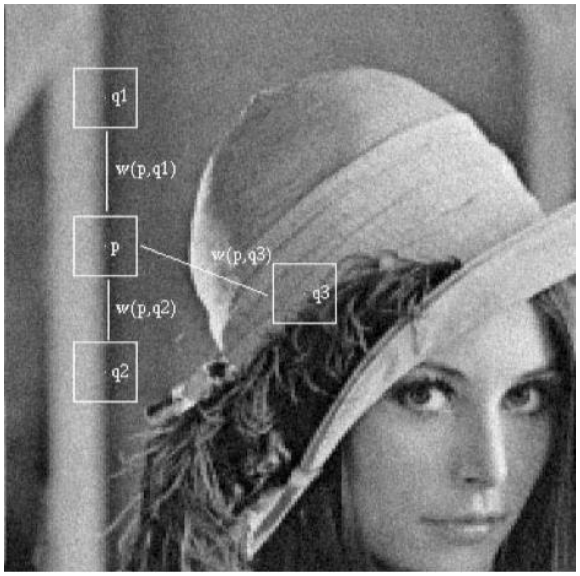

[그림2] NLM Filter 작동 원리

위의 그림은 NLM Filter의 작동 방식을 직관적으로 보여줍니다. 이미지에서 p 지점의 픽셀을 denoising을 하고 싶다고 했을 때, 사각형 형태의 주변 픽셀을 포함하는 bounding box를 생성합니다. q1, q2, q3는 p를 제외한 이미지 내의 픽셀로 정의됩니다. q1, q2, q3에도 마찬가지로 bounding box를 생성하고 p의 bounding box와 q1, q2, q3의 bounding box와의 유사도를 계산합니다. 유사도는 Euclidean 거리를 사용하며, gaussian 커널에 mapping되어 최종 가중치를 산출하게 됩니다. 위 그림에서 보다시피 p1, p2의 bounding box는 p의 bounding box와 유사하지만, q3의 bounding box는 유사하지 않습니다. 따라서 p 픽셀은 0.05 * q1 + 0.05 * q2 + 0.00001 * q3와 같은 방식으로 픽셀이 계산됩니다. 즉, p픽셀의 denoising 값은 이미지 내에 존재하는 모든 픽셀의 가중치 선형결합을 통해 생성되게 됩니다. 만약 이미지의 픽셀 개수가 224 x 224라면 50176번의 연산이 진행되어야 합니다.

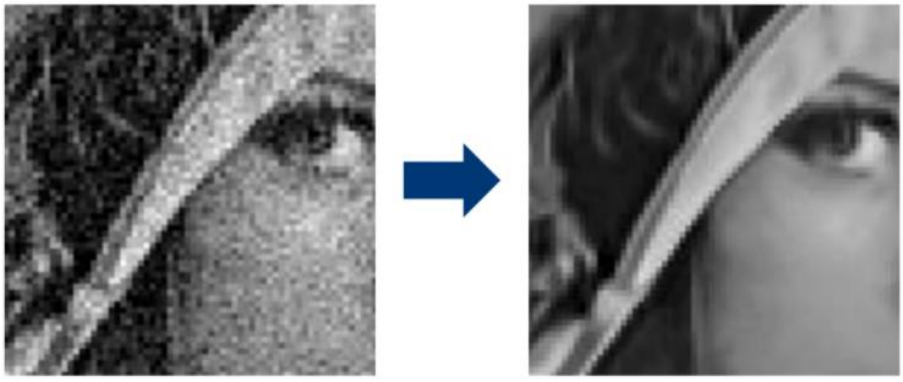

[그림3] NLM Filter 적용 결과

NLM filter는 연산량이 많지만, 좋은 성능을 가지고 있기 때문에 많이 응용되고 있습니다. NLM이라는 이름에서 드러나듯이 다른 필터들과 가장 큰 차이점은 영상 주변부(local)만을 이용한 것이 아니라 영상 전체 영역(non-local)을 활용하는 필터라는 점입니다.

3. Proposed Method

NLM Filter의 핵심은 이미지 전체 영역, 즉 non-local한 영역에서, 서로 간의 유사도를 측정하고 이를 활용하는데 있습니다. 우리가 많이 사용하는 기존의 CNN의 경우는 엄밀히 보면 local한 특성만을 볼 수 있는 구조입니다. 본 연구의 시작은 non-local operator를 네트워크에 추가하면, 이전에는 인식하지 못하던 영상의 새로운 특성을 네트워크가 학습할 수 있을 것이라는 기대에서 출발합니다. 논문의 저자는 NLM Filter의 아이디어를 차용해서 non-local block이라는 구조를 제안했습니다.

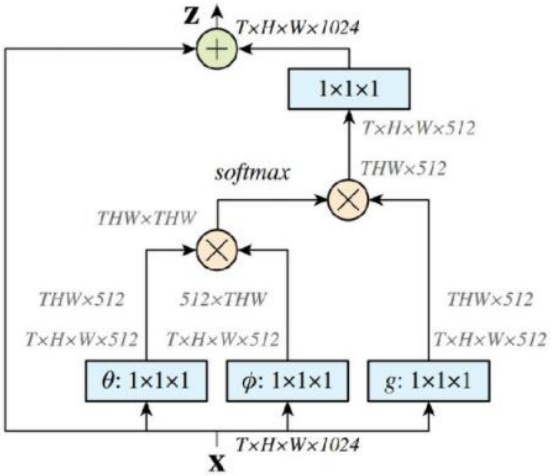

[그림4] Non local block

$$\mathbf{y}_i = \frac{1}{\mathcal{C}(\mathbf{x})} \sum_{\forall j} f(\mathbf{x}_i, \mathbf{x}_j) g(\mathbf{x}_j).$$

$$f(\mathbf{x}_i, \mathbf{x}_j) = e^{\theta(\mathbf{x}_i)^T \phi(\mathbf{x}_j)}$$

본 논문에서는 비디오 데이터를 사용하였기 때문에 T라는 시간 축이 포함되어 있지만, 이미지로 생각할 경우, 단순하게 T가 없다고 생각하면 됩니다. 수식과 그림을 통해 전체적인 구조에 대해 살펴보자면 Non-local block의 수식에서 x_i의 위치에 대한 결과를 만들기 위해 x_i와 그 외 각 모든 영역 x_j와의 관계를 $f(x_i, x_j)$를 통해 계산합니다. θ, $\emptyset$는 채널을 줄이기 위한 1x1 convolution을 수행합니다. 1x1 convolution을 통과한 값들은 관계를 계산하기 위해서 HW × C와 C × HW의 dot product 연산을 수행합니다. 함수 f는 NLM filter에서 유사도를 계산하는 것과 같은 개념으로 생각할 수 있습니다. 유사도는 embedded gaussian 커널에 mapping되어 유사도를 산출하게 됩니다. g(x_j)는 NLM filter로 생각하면 x_i와 비교할 pixel에 해당하는 값인데, 네트워크 연산에 적합하게 만들기 위하여 W_g라는 weight matrix에 곱하여 생성하게 됩니다.

Similarity를 측정하는 함수 f에 어떤 커널을 사용할 것인가는 본 논문에서도 중요하게 다루고 있는 문제인데 결론적으로 커널의 종류보다는 similarity를 측정하는 행위 자체가 중요한 것으로 이야기하고 있습니다.

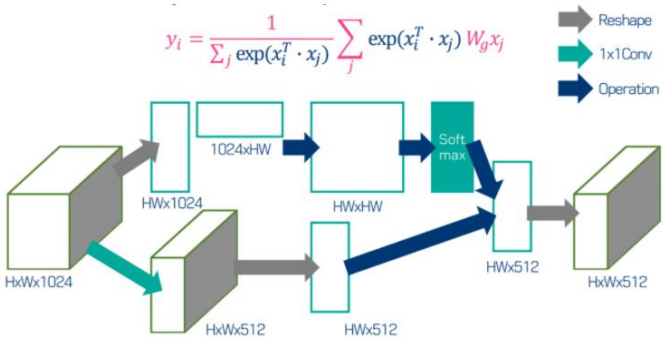

[그림5] Non local block 행렬 연산 예시

4. Experiments(Code Review)

(1) Non-local block

Non-local block은 행렬곱 연산과 point-wise plus 연산으로 구성되기 때문에 __init__과 forward만으로도 좌측 그림의 흐름대로 구성할 수 있습니다.

```
import torch
from torch import nn
from torch.nn import functional as F


class _NonLocalBlockND(nn.Module):
    def __init__(self, in_channels, inter_channels=None, dimension=3, sub_sample=True, bn_layer=True):

        super(_NonLocalBlockND, self).__init__()

        assert dimension in [1, 2, 3]

        self.dimension = dimension
        self.sub_sample = sub_sample

        self.in_channels = in_channels
        self.inter_channels = inter_channels

        if self.inter_channels is None:
            self.inter_channels = in_channels // 2
            if self.inter_channels == 0:
                self.inter_channels = 1

        if dimension == 3:
            conv_nd = nn.Conv3d
            max_pool_layer = nn.MaxPool3d(kernel_size=(1, 2, 2))
            bn = nn.BatchNorm3d
        elif dimension == 2:
            conv_nd = nn.Conv2d
            max_pool_layer = nn.MaxPool2d(kernel_size=(2, 2))
            bn = nn.BatchNorm2d
        else:
            conv_nd = nn.Conv1d
            max_pool_layer = nn.MaxPool1d(kernel_size=(2))
            bn = nn.BatchNorm1d

        self.g = conv_nd(in_channels=self.in_channels, out_channels=self.inter_channels,
                         kernel_size=1, stride=1, padding=0)

        if bn_layer:
            self.W = nn.Sequential(
                conv_nd(in_channels=self.inter_channels, out_channels=self.in_channels,
                        kernel_size=1, stride=1, padding=0),
                bn(self.in_channels)
            )
            nn.init.constant_(self.W[1].weight, 0)
            nn.init.constant_(self.W[1].bias, 0)
        else:
            self.W = conv_nd(in_channels=self.inter_channels, out_channels=self.in_channels,
                             kernel_size=1, stride=1, padding=0)
            nn.init.constant_(self.W.weight, 0)
            nn.init.constant_(self.W.bias, 0)

        self.theta = conv_nd(in_channels=self.in_channels, out_channels=self.inter_channels,
                             kernel_size=1, stride=1, padding=0)
        self.phi = conv_nd(in_channels=self.in_channels, out_channels=self.inter_channels,
                           kernel_size=1, stride=1, padding=0)

        if sub_sample:
            self.g = nn.Sequential(self.g, max_pool_layer)
            self.phi = nn.Sequential(self.phi, max_pool_layer)

    def forward(self, x, return_nl_map=False):

        batch_size = x.size(0)

        g_x = self.g(x).view(batch_size, self.inter_channels, -1)
        g_x = g_x.permute(0, 2, 1)

        theta_x = self.theta(x).view(batch_size, self.inter_channels, -1)
        theta_x = theta_x.permute(0, 2, 1)
        phi_x = self.phi(x).view(batch_size, self.inter_channels, -1)
        f = torch.matmul(theta_x, phi_x)
        f_div_C = F.softmax(f, dim=-1)

        y = torch.matmul(f_div_C, g_x)
        y = y.permute(0, 2, 1).contiguous()
        y = y.view(batch_size, self.inter_channels, *x.size()[2:])
        W_y = self.W(y)
        z = W_y + x

        if return_nl_map:
            return z, f_div_C
        return z
```

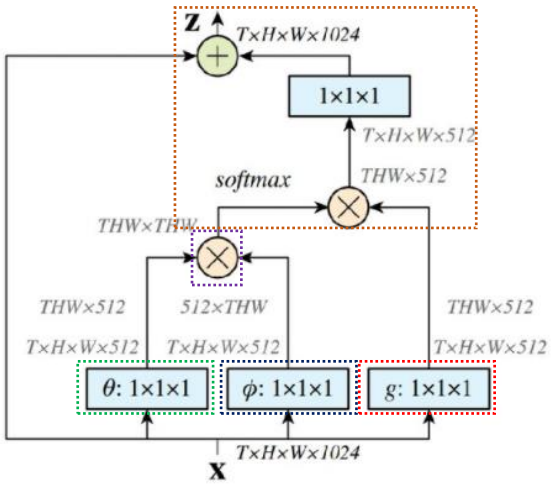

(2) Network

네트워크는 총 3개의 convolution과 2개의 non-local block으로 구성되어 있습니다. CNN이 해당 이미지를 분류할 때 추론한 히트맵과 Non local block이 이미지에서 가장 중요하다고 생각한 부분을 나타내는 구역의 차이를 시각화하기 위해 forward_with_nl_map을 활용하였습니다.

```
class Network(nn.Module):
    def __init__(self):
        super(Network, self).__init__()

        self.conv_1 = nn.Sequential(
            nn.Conv2d(in_channels=1, out_channels=32, kernel_size=3, stride=1, padding=1),
            nn.BatchNorm2d(32),
            nn.ReLU(),
            nn.MaxPool2d(2),
        )

        self.nl_1 = NONLocalBlock2D(in_channels=32)
        self.conv_2 = nn.Sequential(
            nn.Conv2d(in_channels=32, out_channels=64, kernel_size=3, stride=1, padding=1),
            nn.BatchNorm2d(64),
            nn.ReLU(),
            nn.MaxPool2d(2),
        )

        self.nl_2 = NONLocalBlock2D(in_channels=64)
        self.conv_3 = nn.Sequential(
            nn.Conv2d(in_channels=64, out_channels=128, kernel_size=3, stride=1, padding=1),
            nn.BatchNorm2d(128),
            nn.ReLU(),
            nn.MaxPool2d(2),
        )

        self.fc = nn.Sequential(
            nn.Linear(in_features=128*3*3, out_features=256),
            nn.ReLU(),
            nn.Dropout(0.5),

            nn.Linear(in_features=256, out_features=10)
        )
    def forward_with_nl_map(self, x):
        batch_size = x.size(0)

        feature_1 = self.conv_1(x)
        nl_feature_1, nl_map_1 = self.nl_1(feature_1, return_nl_map=True)

        feature_2 = self.conv_2(nl_feature_1)
        nl_feature_2, nl_map_2 = self.nl_2(feature_2, return_nl_map=True)

        output = self.conv_3(nl_feature_2).view(batch_size, -1)
        output = self.fc(output)

        return output, [nl_map_1, nl_map_2]


if __name__ == '__main__':
    import torch

    img = torch.randn(3, 1, 28, 28)
    net = Network()
    out = net(img)
    print(out.size())
```

(3) 결과 확인

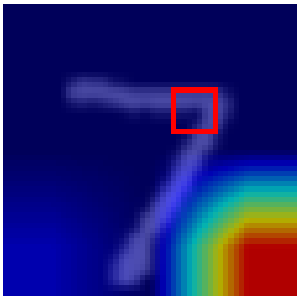

[그림6]두 번째 Non-local layer에 대하여 오분류한 필기체 7 이미지의 시각화 결과

MNIST 데이터에 대해서 네트워크의 epoch을 약 100번정도 실행하였습니다. Test 정확도는 99.39%를 기록하였으며, training 정확도는 99.91%를 기록하였습니다. 중요한 점은 실험에서 epoch 1번만으로도 Test 정확도 96%, training 정확도 98.36%를 기록했다는 점입니다. Non-local block이 CNN의 이미지 분류에 큰 도움을 준다는 것을 알 수 있는 점입니다.

위의 그림은 오분류한 7의 이미지에 대해서 Non-local block이 이미지에서 가장 중요하다고 판단한 부분(빨간색 사각형 box)과 CNN이 해당 이미지를 7이라고 추론한 영역(히트맵)에 대해 시각화한 결과입니다. CNN은 위의 이미지를 판단할 때 전혀 다른 부분을 보고 판단하였기에 7이라는 클래스로 분류를 해내지 못하였지만, non-local block의 결과에서는 7의 꺾이는 부분을 확인한 것을 볼 수 있습니다. 이 결과는 convolution의 local하게 이미지를 본 영역과 다른 시각을 non-local block은 보여준다는 것을 알 수 있습니다.